INFORMATICS FESTIVAL
DATA SCIENCE

SCRIBE

A NUSANTARA SCRIPT CLASSIFICATION MODEL BASED ON

Synthetic-Corruption and Routed Inference across Backbone Experts





M. Fachri Alfaridzi

Riantama Putra

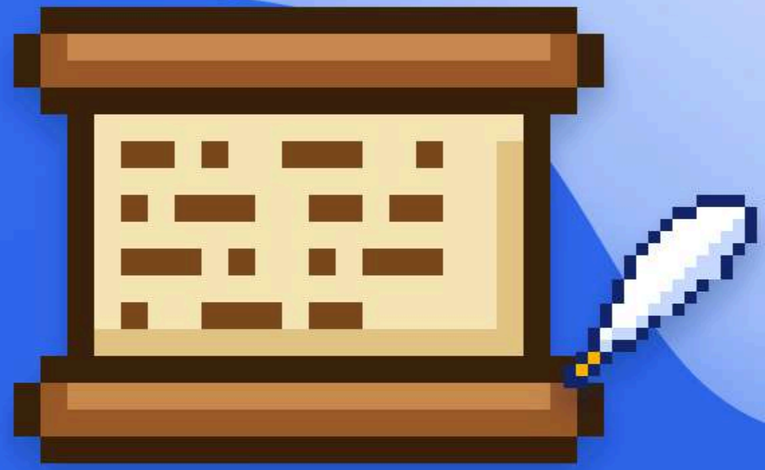
Tiara Kusuma W.

DOAAYAHIBU

INFORMATICS FESTIVAL
DATA SCIENCE

MASALAH

Kenapa skor validasi tinggi, tapi skor uji jatuh?





LATAR BELAKANG



Sumber: Perpusnas, Repatriasi Naskah Kuno dari Luar Negeri 2024; Perpusnas, Ekspos Hasil Pelestarian Naskah Kuno 2024

121.545

naskah kuno tercatat Perpusnas, sekitar 39 ribu ada di luar negeri

763

naskah yang sempat dilestarikan Perpusnas sepanjang 2024

Dengan laju itu, 82.158 naskah di dalam negeri butuh lebih dari 100 tahun.

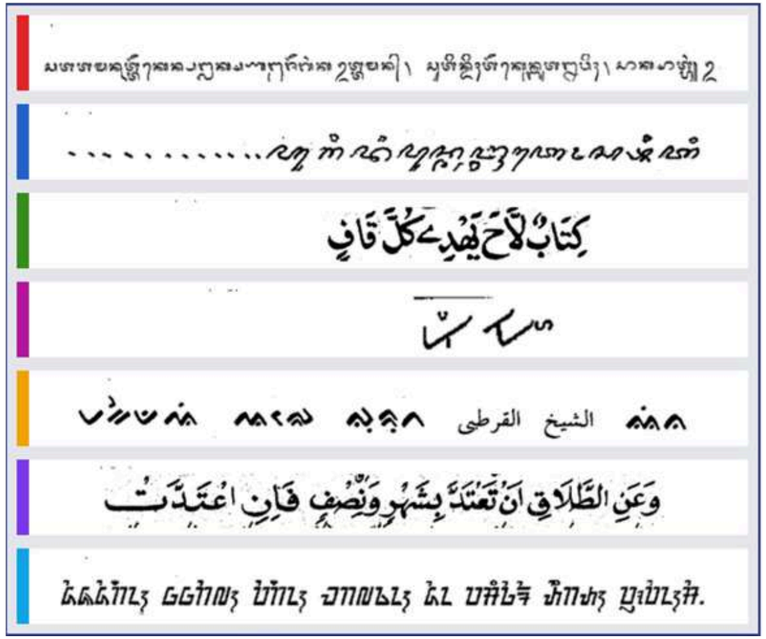
TUJUAN DAN DATASET

Tujuan: model yang mengenali asal aksara Nusantara dari sebuah citra, dan tetap andal saat citra miring, kabur, berwarna, atau berupa halaman penuh.

3.771
citra latih berlabel (PNG dan JPG)

1.220
citra uji tanpa label

- Bali
- Jawa
- Jawi
- Lampung
- Lontara
- Pegon
- Sunda



Input: citra → Output: 1 dari 7 kelas aksara

Manfaat: digitalisasi naskah Nusantara lebih cepat

KUNCI MASALAH

INFORMATICS FESTIVAL
DATA SCIENCE

0,976

skor validasi baseline (holdout acak)

turun 0,113

0,863

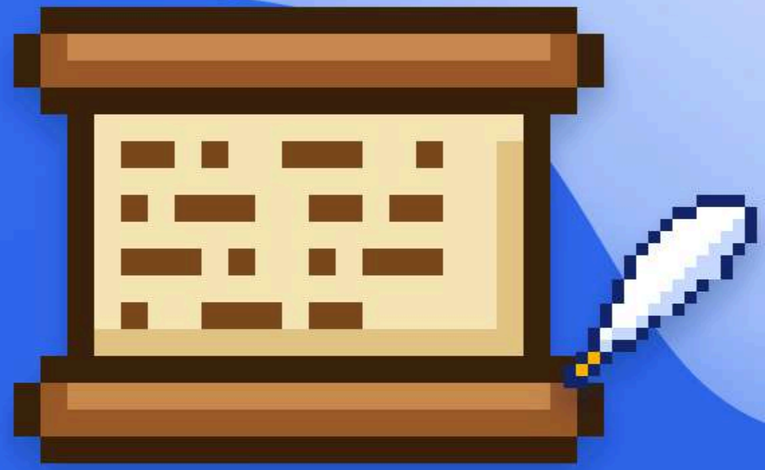
skor Kaggle publik

Skor validasi tinggi tidak menjamin skor uji. Kami membongkar data untuk mencari penyebab selisih ini.

INFORMATICS FESTIVAL
DATA SCIENCE

EKSPLORASI DATA

Lima temuan yang menjelaskan selisih skor





CITRA SANGAT BERAGAM



BARIS 75%



BLOK 11%



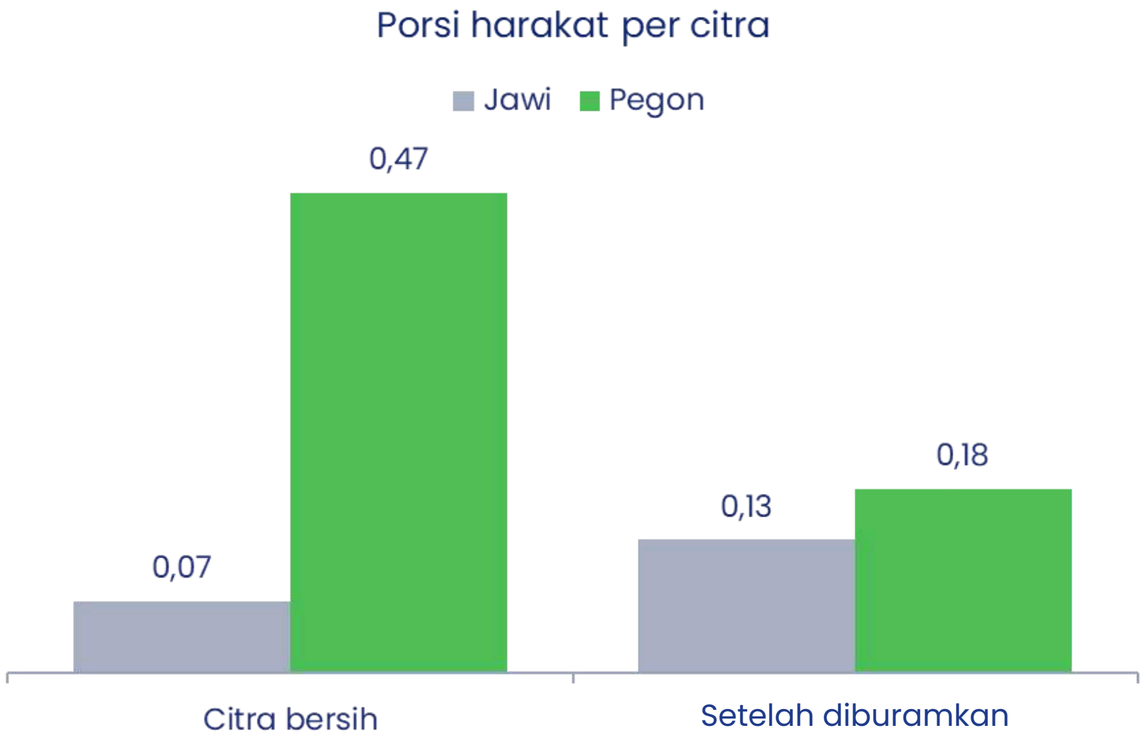
GLYPH 9%

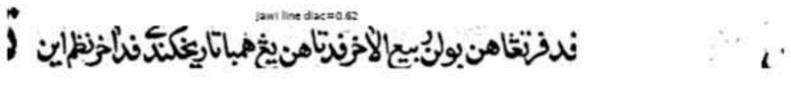


HALAMAN 5%

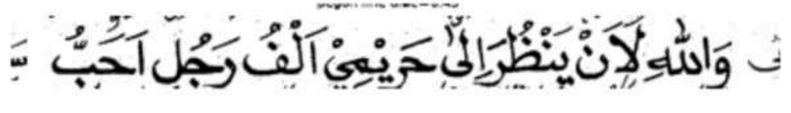
Satu kelas aksara bisa tampil sebagai satu baris, potongan blok, satu huruf, hingga foto halaman penuh.

HURUF SAJA TIDAK CUKUP





Jawi

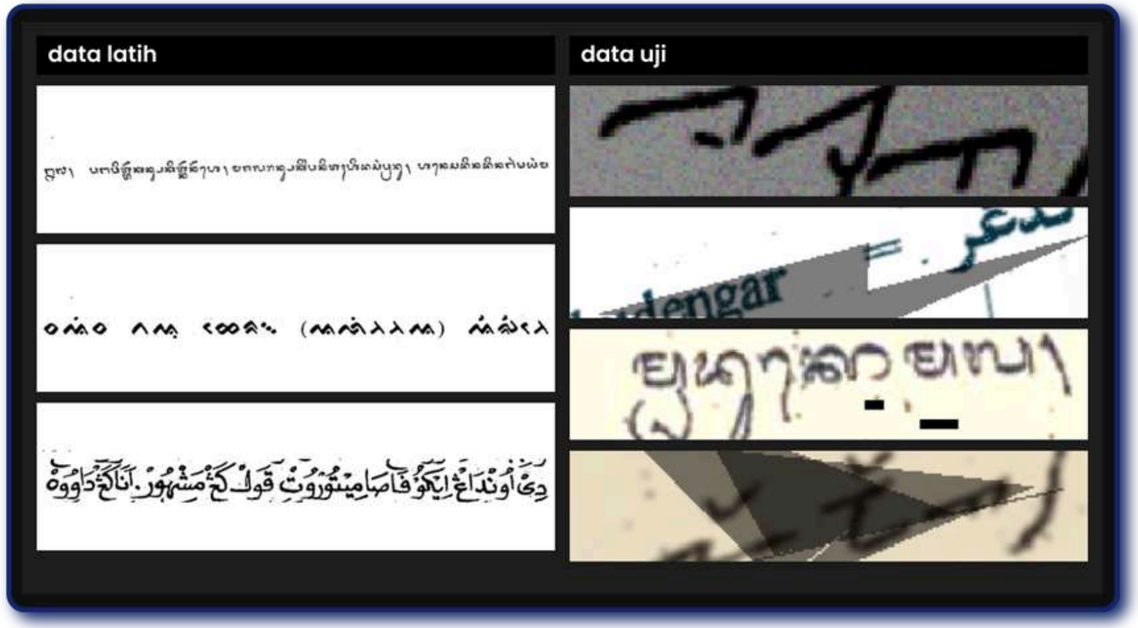


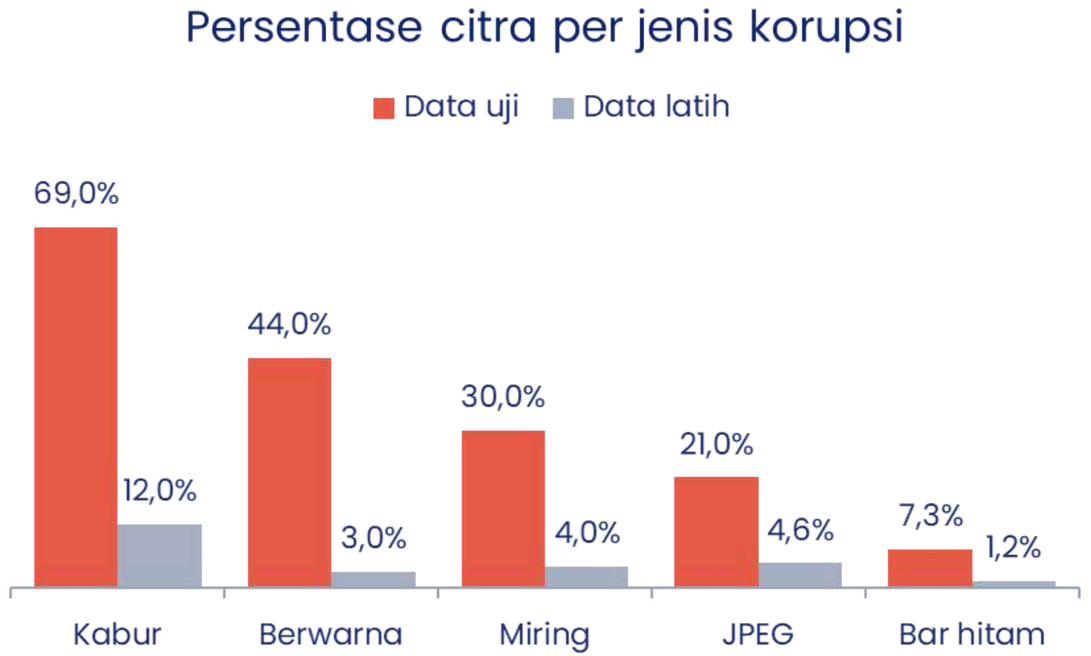
Pegon

Saat dikaburkan, harakat Pegon ikut hilang: 0,47 → 0,18

Jawi dan Pegon memakai huruf Arab yang sama. Model perlu konteks tulisan, bukan sekadar bentuk huruf.

DATA UJI SENGAJA DIRUSAK





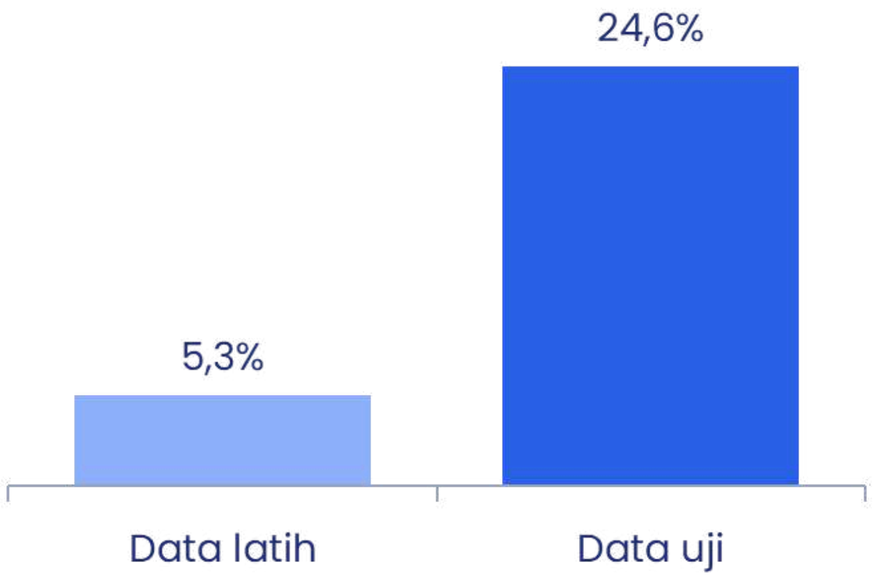
6 dari 10
baris uji berwarna atau kabur

Segitiga abu dan garis hitam hanya ada di data uji. Kerusakan ini sengaja ditambahkan, jadi bisa ditiru.

HALAMAN PENUH DI DATA UJI

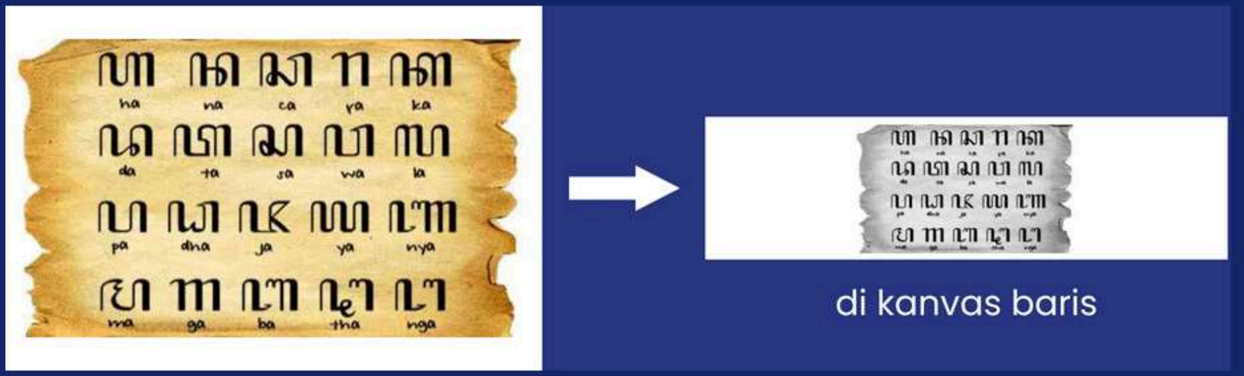
INFORMATICS FESTIVAL DATA SCIENCE

Porsi halaman penuh



Halaman: citra dengan tinggi asli 250 px atau lebih

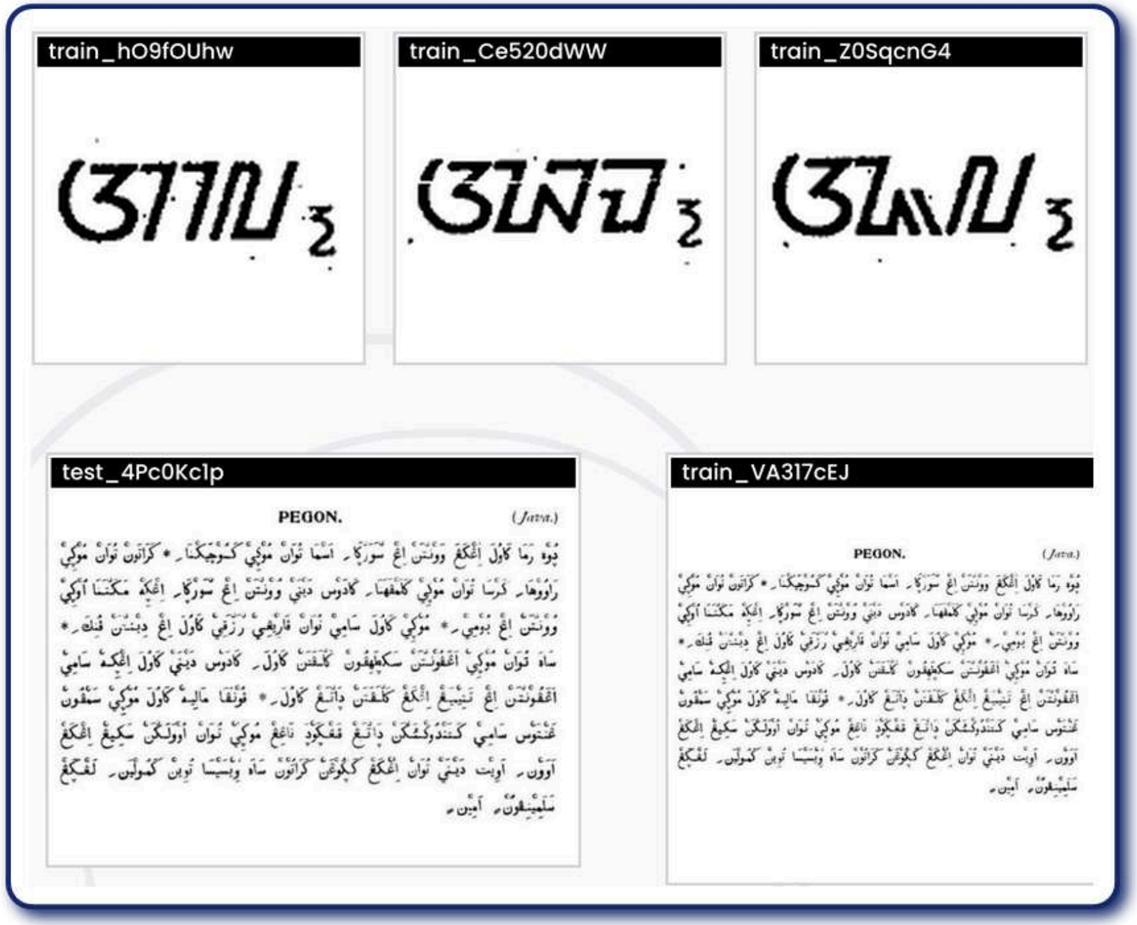
Huruf ikut menyusut



Di kanvas baris, huruf halaman tinggal ±3,5 piksel dan tidak terbaca.

Halaman hanya 1 dari 20 di data latih, tetapi 1 dari 4 di data uji.

CITRA KEMBAR



312

citra latih punya kembaran

17

citra uji kembar dengan citra latih

Risiko: pembagian acak menaruh kembaran di latih dan validasi sekaligus, jadi skor validasi bocor dan terlalu tinggi.

Pemanfaatan: 17 citra uji diberi label kembarannya di data latih (post-processing label twins).

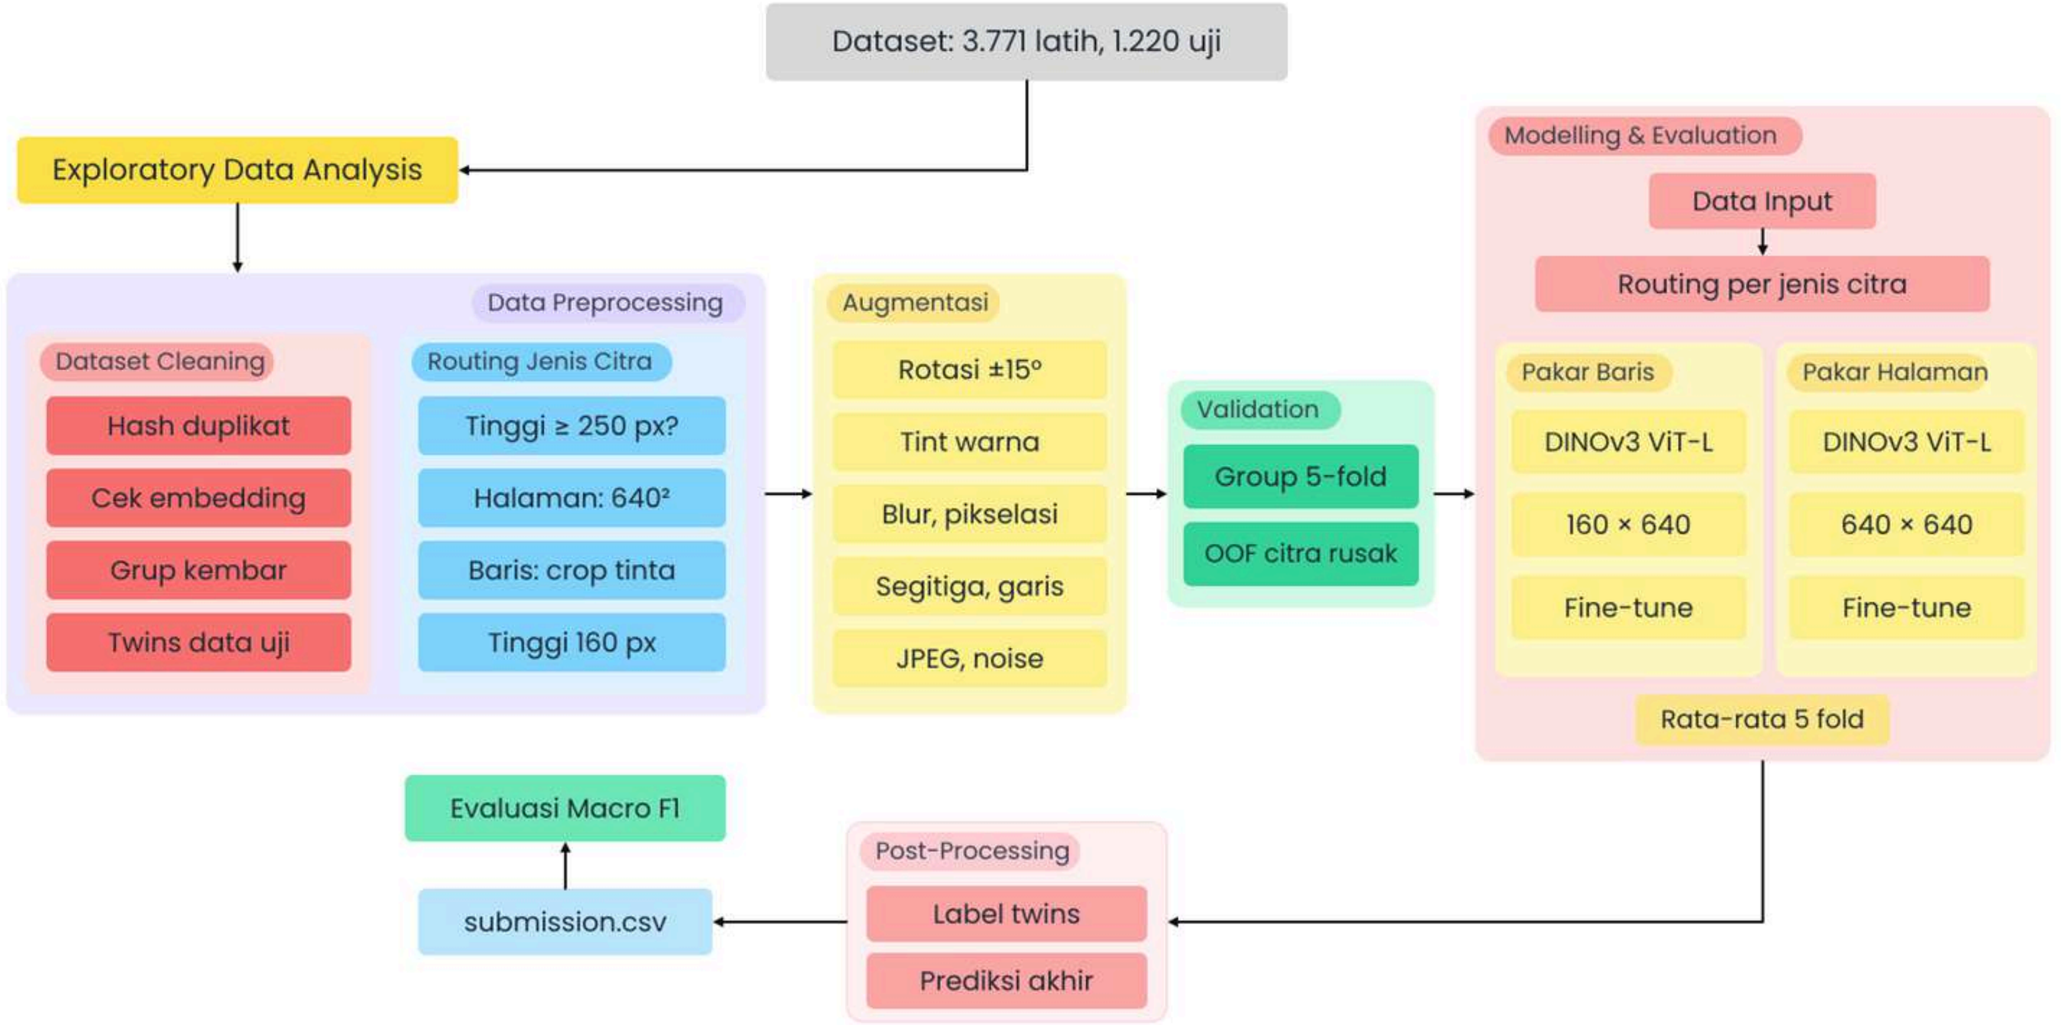
INFORMATICS FESTIVAL
DATA SCIENCE

METODOLOGI

Validasi per grup, korupsi sintetis, dan dua pakar pembaca



ALUR EKSPERIMEN SCRIBE

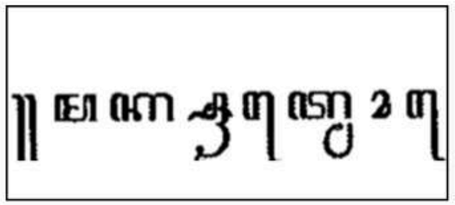


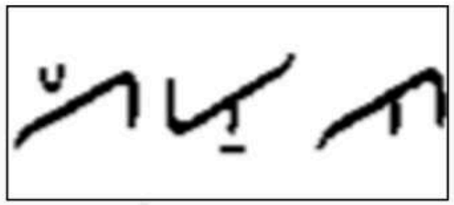
VALIDASI PER GRUP

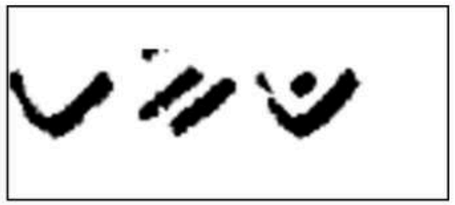


KORUPSI SINTETIS

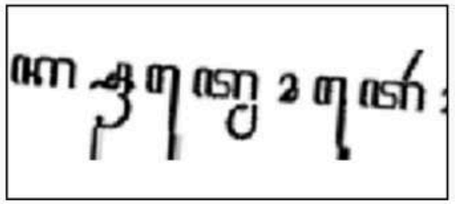
ASLI



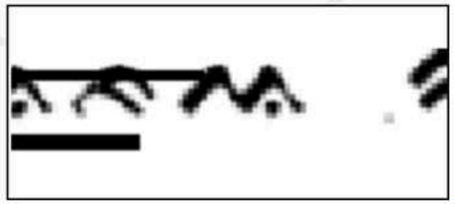




RUSAK







Kerusakan pada data uji ditiru saat latihan. Validasi juga dinilai pada citra rusak (OOF citra rusak), jadi skor lokal lebih jujur.

Augmentasi saat latihan

- Rotasi ±15°
- Tint warna
- Blur dan pikselasi
- Segitiga abu dan garis hitam
- Kompresi JPEG dan noise

DUA PAKAR PEMBACA

1 ROUTING



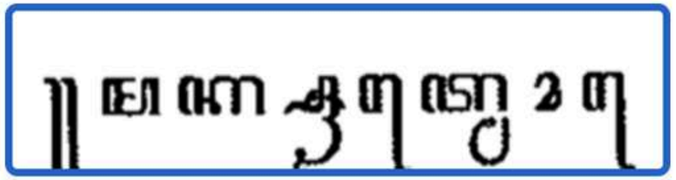
≥ 250 px
→ halaman



< 250 px
→ baris

Tinggi asli citra menentukan pakar yang membaca.

2 PAKAR BARIS





Crop ke tinta, tinggi 160 px, dibaca per jendela 640. Dilatih dengan korupsi (v2).

3 PAKAR HALAMAN



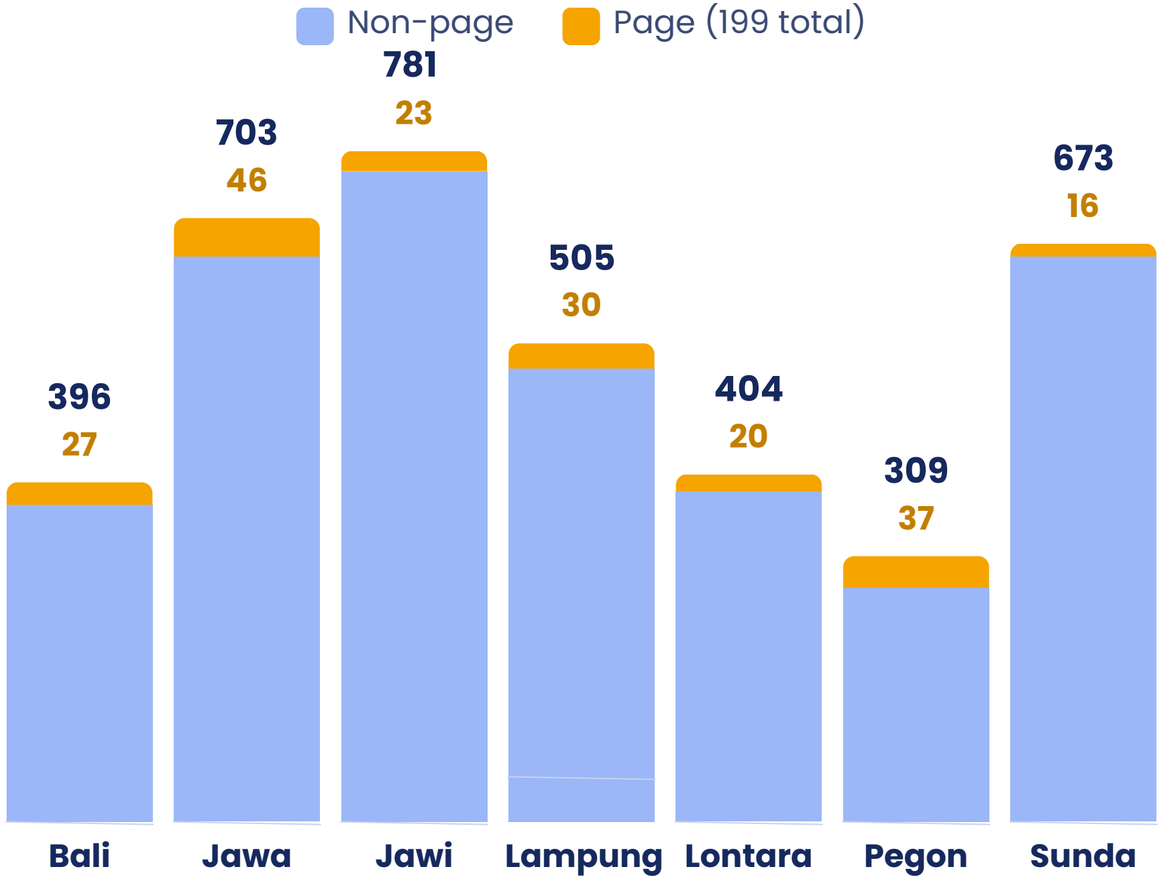
Dibaca utuh 640 × 640 skala abu, huruf tetap besar (v5).

Backbone: DINOv3 ViT-L/16

KELAS DAN METRIK EVALUASI

INFORMATICS FESTIVAL DATA SCIENCE

Jumlah citra latih per kelas



Macro F1

$$\text{Macro F1} = \frac{1}{7}\sum_{c=1}^{7}\frac{2\,P_c\,R_c}{P_c + R_c}$$

Akurasi Page

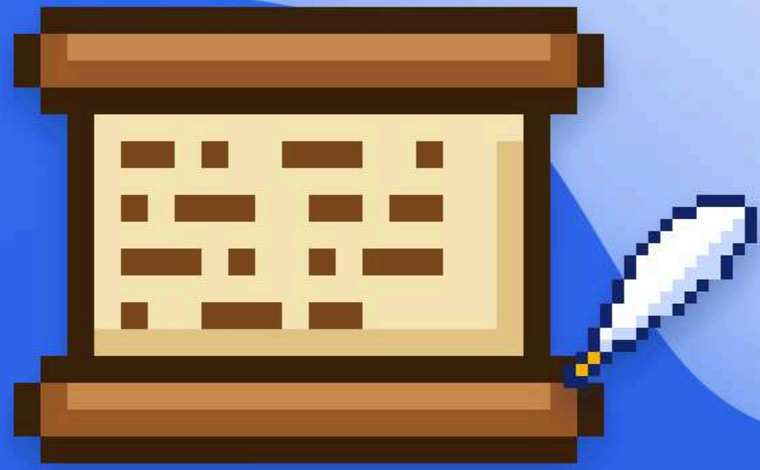
$$\text{Acc}_{\text{page}} = \frac{1}{|\mathcal{P}|}\sum_{i\in\mathcal{P}} 1[\hat{y}_i = y_i]$$

Metrik	Yang dinilai
F1 Clean	semua citra bersih
F1 Corrupt	semua dikorupsi
F1 Testlike	page bersih, lain korup
Acc Page	199 page, bersih

INFORMATICS FESTIVAL
DATA SCIENCE

MODELING DAN HASIL

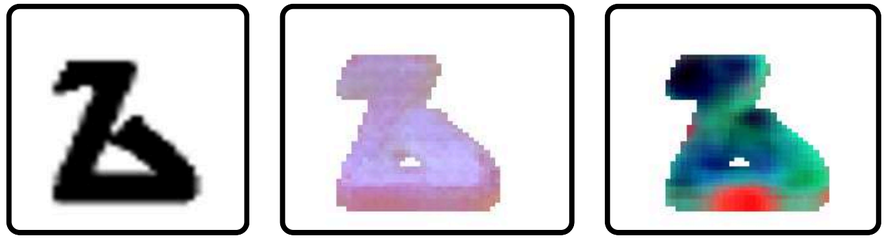
Eksperimen, ablation, dan analisis kesalahan





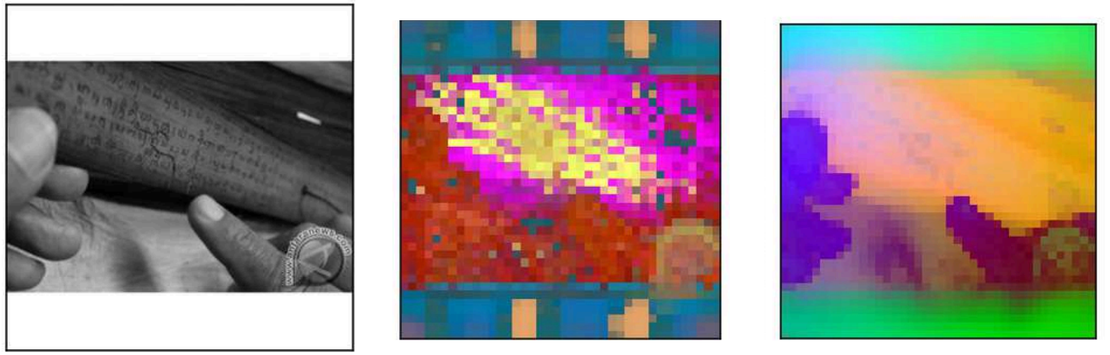
PENGARUH ARSITEKTUR

Pengujian Terhadap Input Baris



Input DinoV3 ConvnextV2

Pengujian Terhadap Input Page



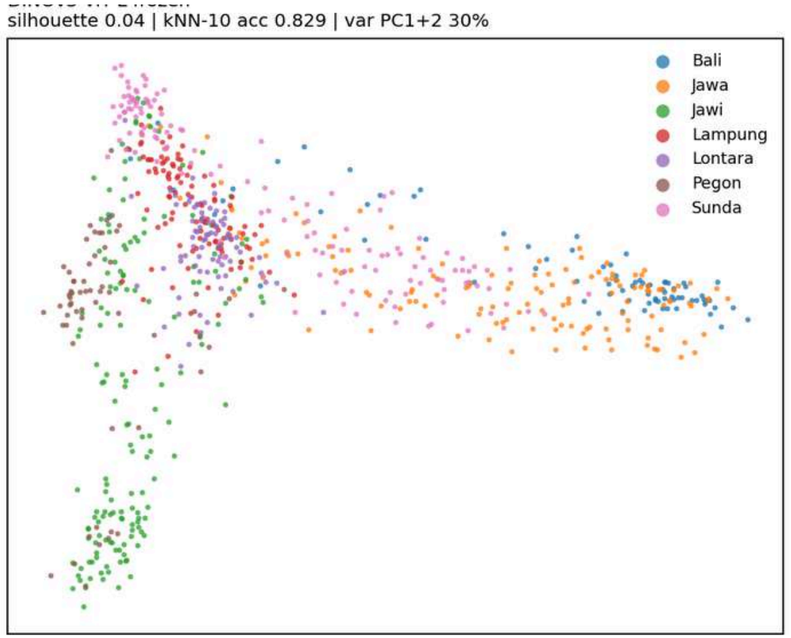
Input ConvNextV2 DinoV3

**Tiap model menggunakan probing fitur beku*

Semua model sudah mengenali bentuk aksara dalam baris , tetapi CNN masih kesulitan menangkap citra Page sedangkan DINOv3 jauh lebih halus dan stabil.

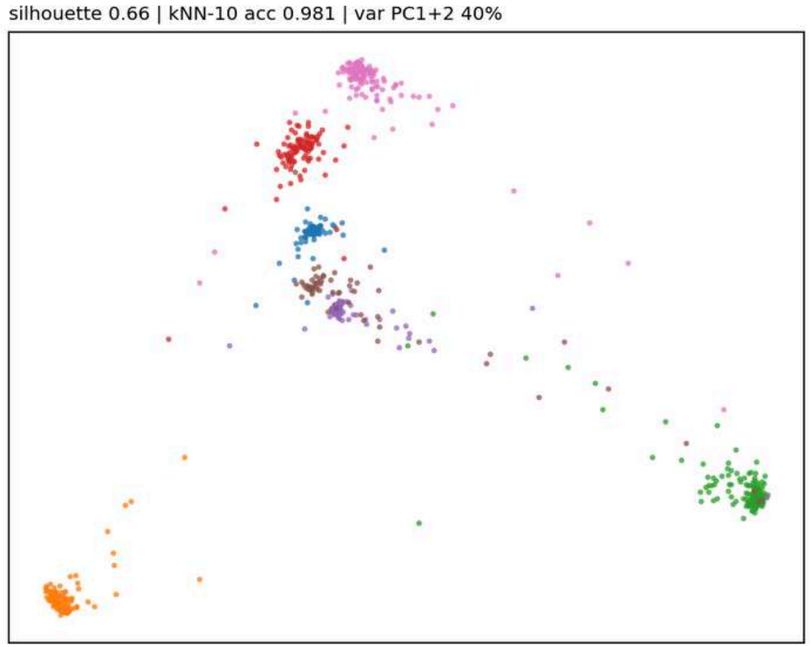
PENGARUH FINE TUNING

DinoV3 ViT-L (Frozen)



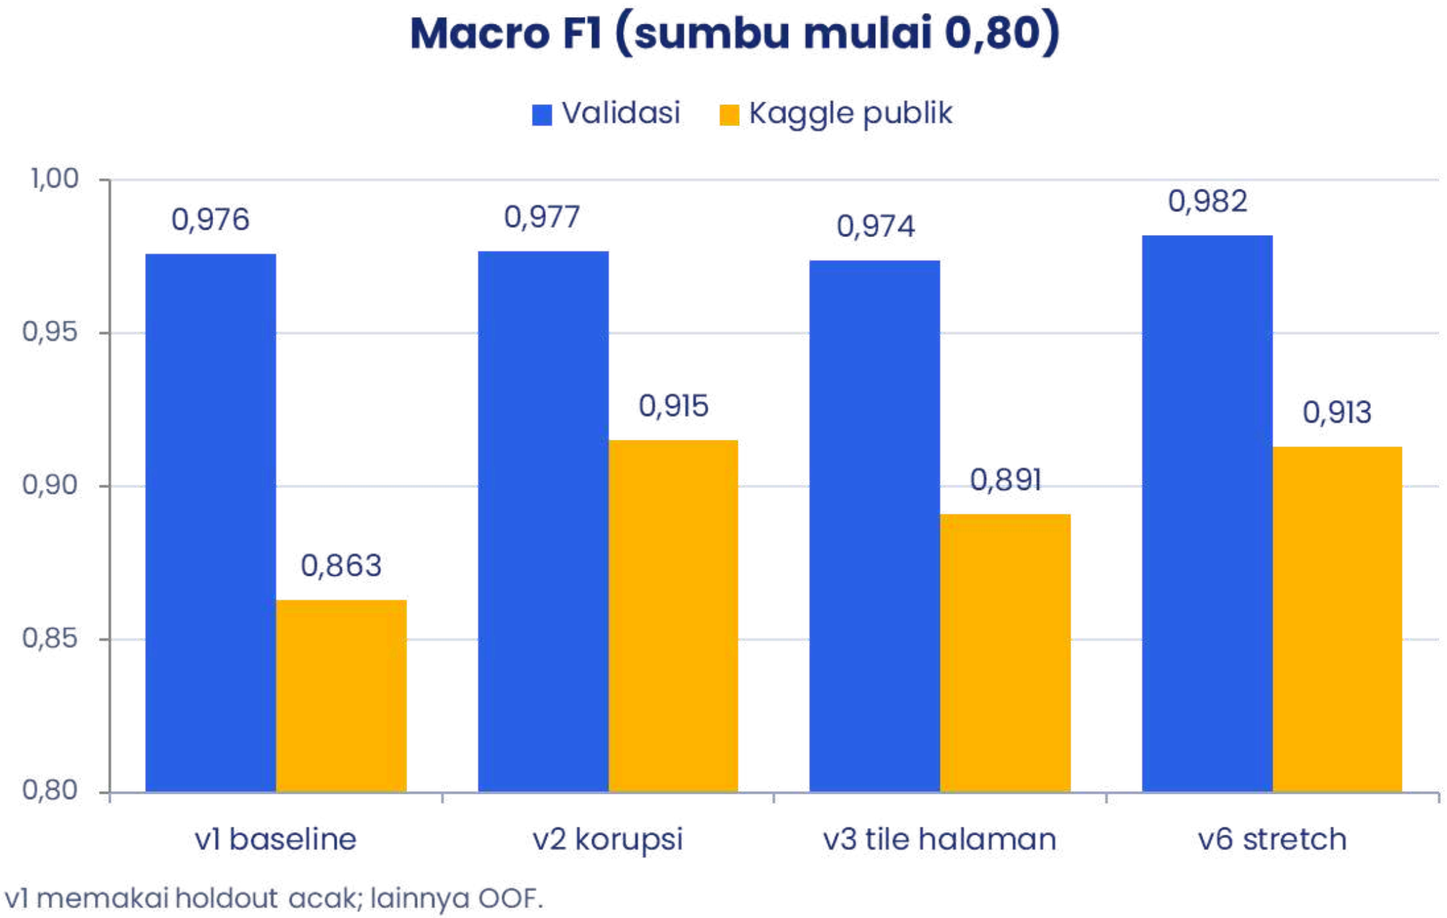
Fine Tuning

DinoV3 ViT-L (Fine Tuned)



DinoV3 fitur frozen pada ketujuh aksara masih bertumpuk. Setelah fine tuning setiap aksara membentuk kelompok sendiri yang terpisah jelas.

EKSPERIMEN AWAL



v1 memakai holdout acak; lainnya OOF.

0,974–0,982

rentang validasi: hampir sama

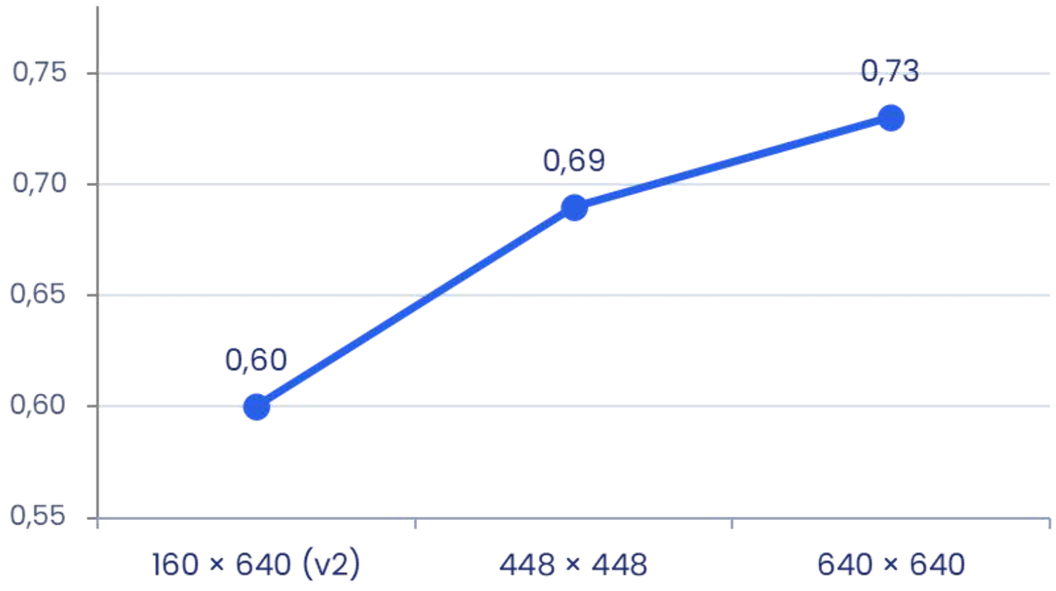
0,863–0,915

rentang publik: jauh lebih lebar

Validasi lokal belum bisa membedakan model yang bagus di data uji.

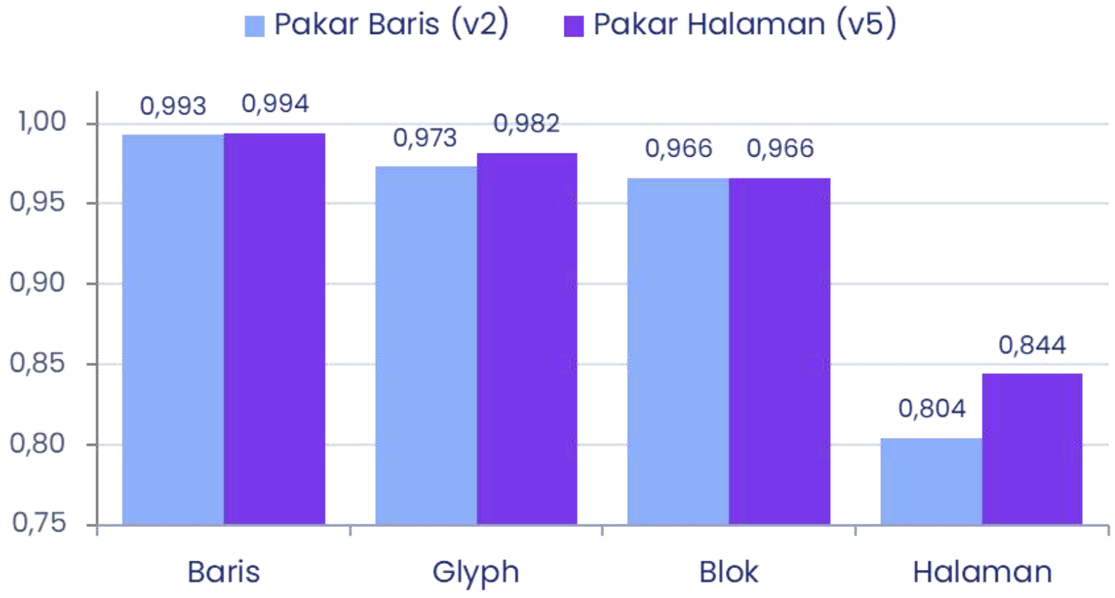
KENAPA PERLU PAKAR HALAMAN

Probe DINOv3 beku, 199 halaman latih



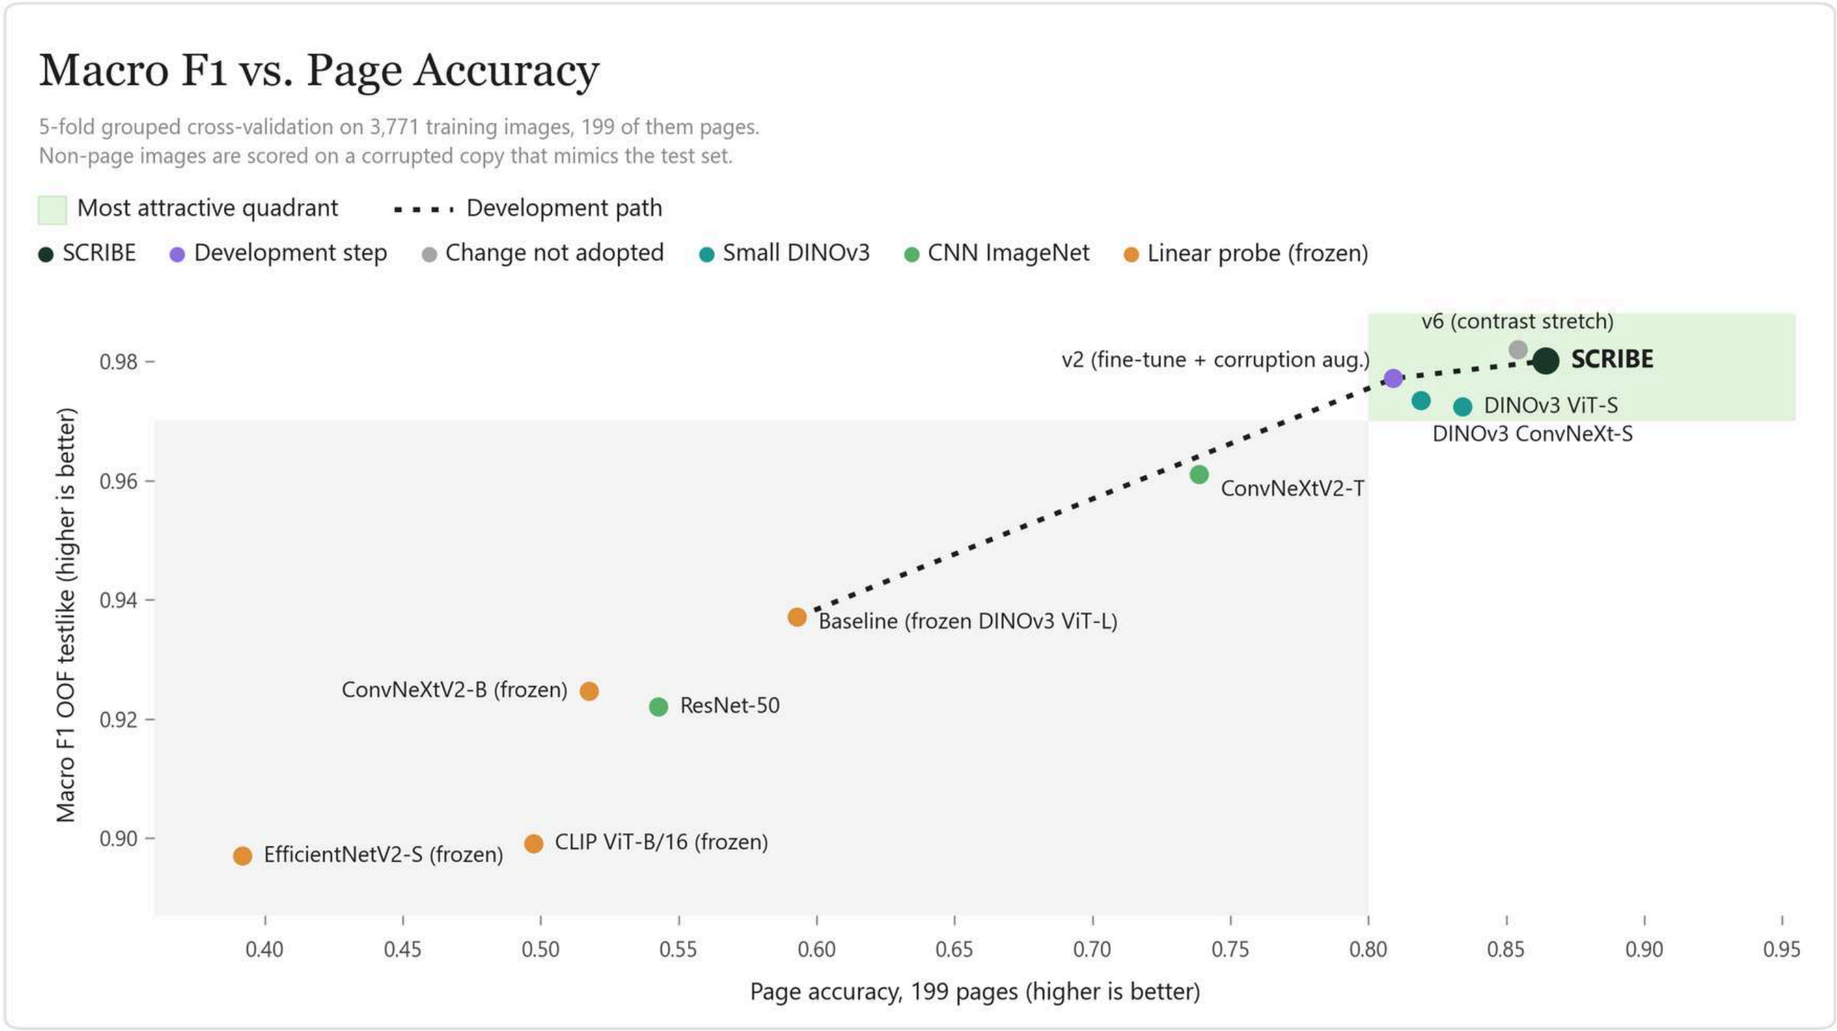
640 × 640 menaikkan akurasi probe +0,13 dari kanvas baris

Akurasi OOF per jenis citra



Halaman benar 160 → 168 dari 199 (+8). Publik 0,91514 → 0,91820.

BENCHMARK


Macro F1 vs. Page Accuracy
5-fold grouped cross-validation on 3,771 training images, 199 of them pages.
Non-page images are scored on a corrupted copy that mimics the test set.
Most attractive quadrant
Development path
SCRIBE
Development step
Change not adopted
Small DINOv3
CNN ImageNet
Linear probe (frozen)
v6 (contrast stretch)
v2 (fine-tune + corruption aug.)
SCRIBE
DINOv3 ViT-S
DINOv3 ConvNeXt-S
ConvNeXtV2-T
Baseline (frozen DINOv3 ViT-L)
ConvNeXtV2-B (frozen)
ResNet-50
EfficientNetV2-S (frozen)
CLIP ViT-B/16 (frozen)
Macro F1 OOF testlike (higher is better)
0.98
0.96
0.94
0.92
0.90
0.40
0.45
0.50
0.55
0.60
0.65
0.70
0.75
0.80
0.85
0.90
0.95
Page accuracy, 199 pages (higher is better)

ABLATION DAN KOMBINASI MODEL

Konfigurasi	Yang berubah	OOF	Publik
v1 baseline	holdout acak, citra bersih	0,976*	0,863
v2 Pakar Baris	group 5-fold + latihan dengan korupsi	0,977	0,91514
hybrid B (dipakai)	**+ Pakar Halaman v5 untuk halaman**	**0,9801**	**0,91820**
v5 + v11	rata-rata dengan SigLIP2	0,9836	0,91815
ViT-7B LoRA	holdout fold 3	0,9841	0,90966
v7	ArcFace + SupCon, kNN	–	0,88808

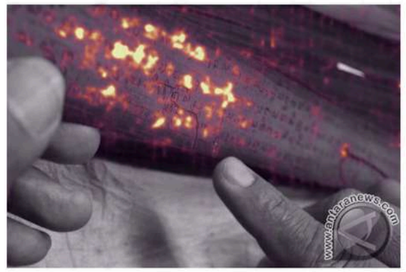
* v1 dinilai dengan holdout acak; konfigurasi lain dengan OOF pada citra rusak.

OOF lebih tinggi tidak menaikkan skor publik (v5 + v11, ViT-7B).

Hybrid B dipilih: setara v5 + v11 (selisih 0,00005), tetapi lebih sederhana dan tanpa tuning bobot.

EXPLAINABLE AI

INFORMATICS FESTIVAL
DATA SCIENCE

Input	SCRIBE	ConvNextV2-L	ResNet-34
			
			

SCRIBE fokus tepat pada goresan aksara sedangkan ConvNeXtV2 dan ResNet justru melihat jari dan tepi gambar.

ANALISIS KESALAHAN

INFORMATICS FESTIVAL DATA SCIENCE

asli \ tebakan	Bali	Jawa	Jawi	Lampung	Lontara	Pegon	Sunda
Bali	**388**	5	2	0	1	0	0
Jawa	4	**695**	1	0	3	0	0
Jawi	0	0	**765**	1	2	**10**	3
Lampung	0	0	1	**503**	1	0	0
Lontara	0	0	2	0	**400**	1	1
Pegon	0	1	**23**	0	0	**283**	2
Sunda	0	3	4	2	1	1	**662**

Confusion matrix OOF hybrid B (baris: label asli, kolom: tebakan)

44%

error OOF ada di Jawi dan Pegon
(33 dari 75)

Arahnya condong: 23 Pegon ditebak Jawi, hanya 10 sebaliknya.

Jika semua error Jawi/Pegon benar, Macro F1 naik +0,011.

HASIL AKHIR

Pakar Baris (v2) + Pakar Halaman (v5) + Routing per jenis citra

0.980

OOF Macro F1

0.91820

Public Score

0.93349

Private Score

INFORMATICS FESTIVAL
DATA SCIENCE

PENUTUP

Apa yang berhasil, keterbatasan, dan rencana implementasi



KESIMPULAN

Korupsi Sintetis + **Dua Pakar Pembaca** = **klasifikasi aksara yang tahan foto naskah rusak**

Yang berhasil

- Korupsi sintetis + validasi per grup: publik 0,863 → 0,915
- Pakar Halaman: +8 halaman benar, publik 0,91820

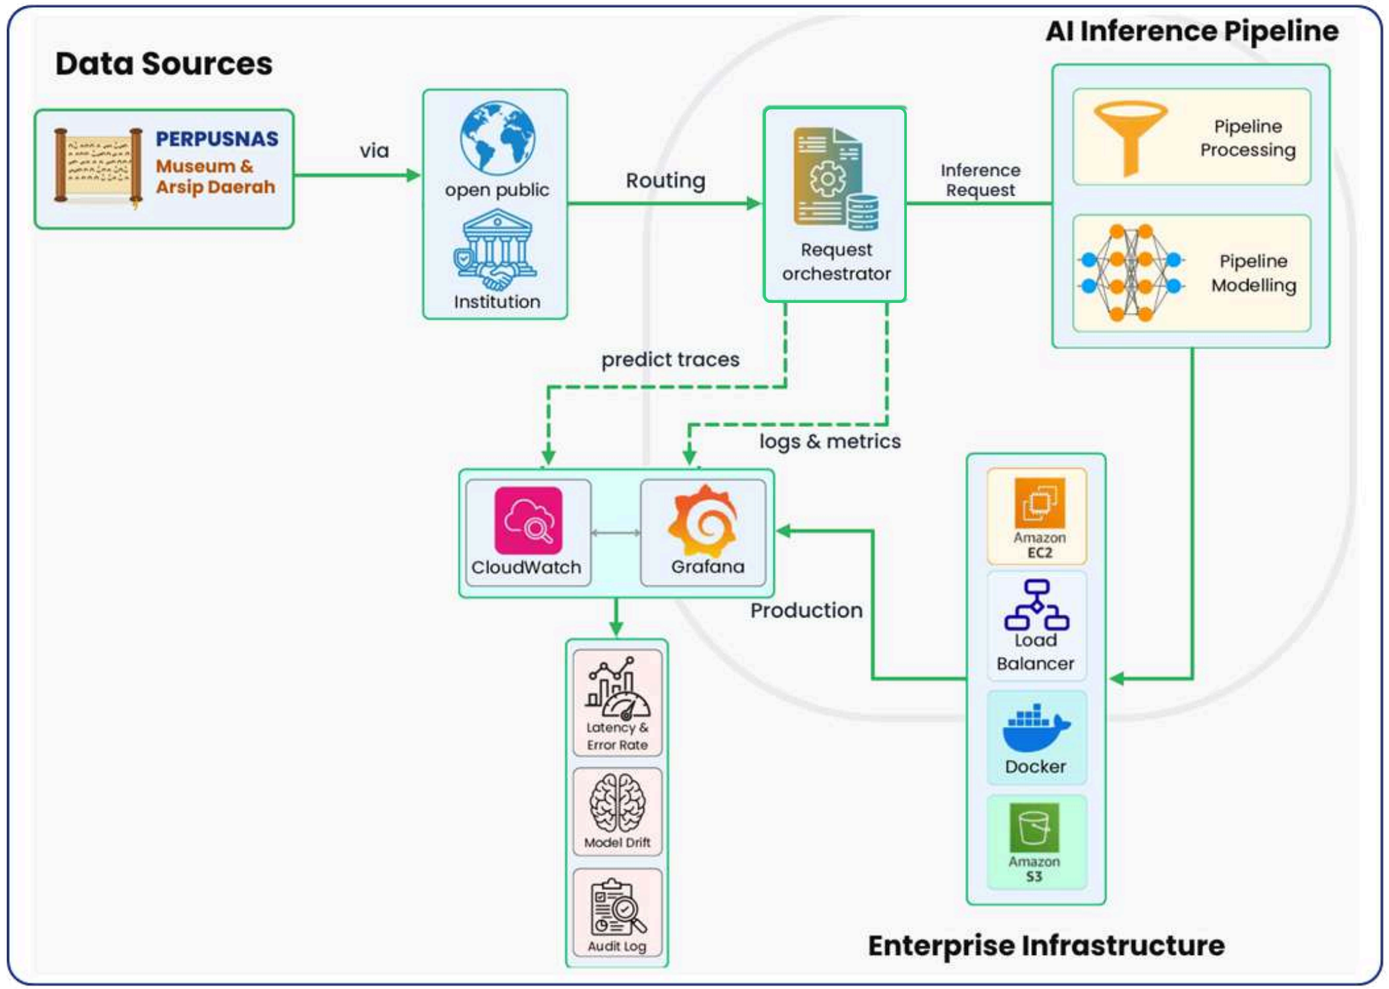
Keterbatasan

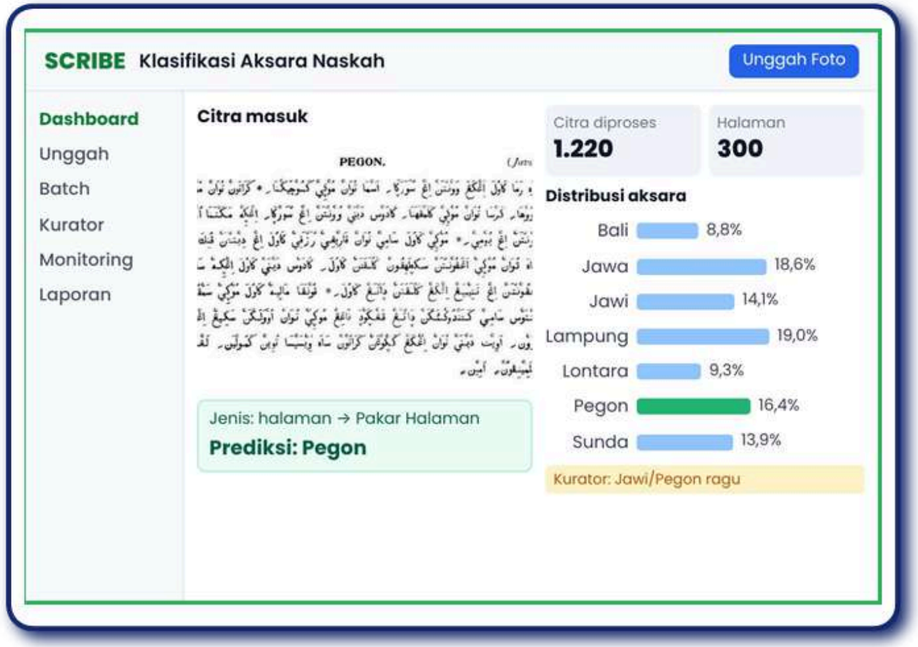
- Selisih OOF dan publik masih sekitar 0,062
- 44% error masih di Jawi dan Pegon

Langkah berikutnya

- Pembeda Jawi dan Pegon yang tidak bergantung pada harakat
- Cari sumber selisih validasi dan data uji

RENCANA IMPLEMENTASI





Dashboard kurator: halaman diarahkan ke Pakar Halaman, dan kasus Jawi/Pegon yang ragu ditandai untuk dicek manusia.

INFORMATICS FESTIVAL
DATA SCIENCE

MATUR NUWUN

DOAAVAHIBU